

Data Quality & Anomaly Detection auf Finanztransaktionsdaten

*Profiling, Quality-Checks und Isolation Forest am Beispiel des Fraud Detection
Dataset*

Projektbericht — Big Data Management, Sommersemester 2026

Alain Zidane Momo Fofou
Matrikelnummer: 602032
Wirtschaftsinformatik B.Sc.
TU Clausthal

Betreuer: M.Sc. Denis Kruschinski
Abgabedatum: 14.08.2026

Notebook, Datensatz und Bericht:
<https://github.com/milito34/bdm-fraud-data-quality>

Abstract

Datenqualität ist in Data-Management-Projekten oft der größte Aufwand, bevor sinnvolle Analysen möglich sind. Gerade bei Finanzdaten ist das kritisch, da fehlerhafte Daten zu falschen Entscheidungen und unzuverlässigen Betrugsmodellen führen können.

Diese Arbeit untersucht einen Datensatz mit 51.000 Finanztransaktionen (Fraud Detection Dataset, Kaggle) anhand eines dreistufigen Quality-Konzepts: systematisches Profiling, fünf automatisierte Quality-Checks und Anomalieerkennung mit Isolation Forest.

Das Profiling zeigt fünf Spalten mit jeweils etwa 5 % fehlenden Werten, 1.000 doppelte Transaction_IDs und 3.060 Einträge mit Platzhalterwerten wie „Invalid Method“. Drei von fünf Quality-Checks bestehen ohne Verstöße, zwei zeigen die genannten Probleme. Isolation Forest identifiziert zuverlässig statistische Ausreißer, insbesondere bei Transaction_Amount, erkennt jedoch nur 5,3 % der tatsächlichen Fraud-Fälle.

Zentrale Erkenntnis: Statistische Anomalieerkennung kann Datenqualitätsprobleme gut aufdecken, reicht für die Betrugserkennung allein jedoch nicht aus. Daraus ergeben sich konkrete Handlungsempfehlungen für eine produktive Datenpipeline.

Schlüsselbegriffe: Data Quality, Data Profiling, Quality Checks, Isolation Forest, Fraud Detection, Finanztransaktionen

Inhaltsverzeichnis

Abstract	2
1 Einleitung	3
2 Verwandte Arbeiten	3
3 Konzept	3
3.1 Schritt 1 – Profiling	4
3.2 Schritt 2 – Quality-Checks	4
3.3 Schritt 3 – Anomalieerkennung	4
4 Umsetzung	4
4.1 Datensatz	4
4.2 Profiling	4
4.3 Quality-Checks	5
4.3.1 Interpretation der Checks	5
4.4 Isolation Forest	5
5 Ergebnisse	6
5.1 Datenqualität	6
5.2 Ausreißer	6
5.3 Isolation-Forest-Ergebnisse	6
6 Bewertung der Isolation-Forest-Ergebnisse	7
7 Fazit und Ausblick	7
8 Literaturverzeichnis	8
9 Transparenzangabe zur Nutzung von KI-Tools	8

1 Einleitung

In Data-Management-Projekten entfällt ein großer Teil des Aufwands auf die Datenqualität. Bevor eine Analyse oder ein Machine-Learning-Modell eingesetzt wird, muss geprüft werden, ob die Daten vertrauenswürdig sind. Fehlende Werte, doppelte Einträge oder ungültige Kategorien können dazu führen, dass spätere Analysen falsche Ergebnisse liefern.

In diesem Projekt wird ein Datensatz mit 51.000 Finanztransaktionen systematisch untersucht. Das Ziel ist ein Quality-Konzept mit drei Teilen:

1. **Profiling:** Beschreibung der wichtigsten Eigenschaften des Datensatzes.
2. **Quality-Checks:** Fünf automatisierte Regeln zur Erkennung typischer Probleme.
3. **Anomalieerkennung:** Einsatz des Isolation Forest zur Identifikation ungewöhnlicher Transaktionen.

Die zentrale Fragestellung lautet:

Welche Datenqualitätsprobleme stecken in einem Datensatz mit Finanztransaktionen – gemessen an den Dimensionen von Pipino et al. (2002) – und wie gut erkennt Isolation Forest nach Liu et al. (2008) verdächtige Transaktionen, wenn die Fraud-Labels nicht zum Training verwendet werden?

2 Verwandte Arbeiten

Für dieses Projekt sind drei Arbeiten besonders relevant.

Pipino, Lee und Wang (2002) beschreiben in ihrem Artikel „Data Quality Assessment“, dass Datenqualität ein mehrdimensionales Konzept ist. Sie unterscheiden zwischen subjektiven Einschätzungen (wie Nutzer die Daten wahrnehmen) und objektiven Metriken, die direkt aus den Daten berechnet werden können. Für dieses Projekt sind vor allem die Dimensionen Completeness (Vollständigkeit), Free-of-Error (Fehlerfreiheit) und Consistent Representation (einheitliche Darstellung) relevant, da sie sich direkt auf den untersuchten Datensatz anwenden lassen.

Liu, Ting und Zhou (2008) stellen mit Isolation Forest ein Verfahren vor, das Anomalien nicht über ein Profil normaler Daten erkennt, sondern Anomalien aktiv isoliert. Die Grundidee ist, dass Anomalien „wenige und unterschiedliche“ Datenpunkte sind, die sich dadurch leichter von der restlichen Datenmenge trennen lassen. Der Algorithmus baut viele zufällige Entscheidungsbäume und berechnet für jeden Datenpunkt einen Anomalie-Score zwischen 0 und 1. Ein Vorteil von Isolation Forest ist, dass keine gelabelten Trainingsdaten benötigt werden, was es für die vorliegende Aufgabe besonders geeignet macht.

Einen breiteren methodischen Rahmen liefert der Übersichtsartikel von Abedjan, Golab und Naumann (2015). Die Autoren ordnen Data-Profiling-Aufgaben nach ihrem Umfang: von der Betrachtung einzelner Spalten bis hin zu Abhängigkeiten zwischen mehreren Spalten. Das vorliegende Projekt bewegt sich in der ersten dieser Kategorien, da sämtliche Befunde des Profilings spaltenweise ermittelt werden. Für den Aufbau dieser Arbeit ist jedoch eine zweite Beobachtung der Autoren entscheidend: Profiling endet nicht bei der Beschreibung der Daten, sondern seine Befunde lassen sich in überprüfbare Regeln übersetzen. Schritt 2 des hier entwickelten Konzepts folgt genau diesem Gedanken.

3 Konzept

Das entwickelte Quality-Konzept besteht aus drei aufeinander aufbauenden Schritten.

3.1 Schritt 1 – Profiling

Zunächst wird der Datensatz systematisch beschrieben. Dazu gehören:

- Größe des Datensatzes,
- Datentypen jeder Spalte,
- Anteil fehlender Werte,
- Anzahl von Duplikaten,
- Ausreißer in numerischen Spalten.

3.2 Schritt 2 – Quality-Checks

Auf Basis des Profilings werden fünf konkrete Regeln definiert und automatisiert im Notebook geprüft. Jede Regel untersucht eine bestimmte Eigenschaft, die für die Datenqualität relevant ist, beispielsweise plausible Beträge oder eindeutige IDs.

3.3 Schritt 3 – Anomalieerkennung

Mit Isolation Forest werden Transaktionen identifiziert, die sich stark von der Mehrheit der Daten unterscheiden. Da der Datensatz echte Fraud-Labels enthält, können die erkannten Anomalien anschließend mit den tatsächlichen Betrugsfällen verglichen werden.

Alle drei Schritte wurden in einem Jupyter Notebook mit Pandas, NumPy, scikit-learn, Matplotlib und Seaborn umgesetzt.

4 Umsetzung

4.1 Datensatz

Der verwendete Fraud Detection Dataset (Kaggle) enthält 51.000 Finanztransaktionen mit 12 Spalten. Neben der Transaction_ID enthält er Informationen zu Transaktionsbetrag, Transaktionszeitpunkt, Gerät, Standort, Zahlungsmethode sowie die Spalte Fraudulent.

4.2 Profiling

Beim Profiling wurden folgende Befunde festgestellt:

- Fünf Spalten weisen jeweils etwa 5 % fehlende Werte auf.
- 1.000 Transaction_IDs kommen doppelt vor; 881 Zeilen sind komplette Duplikate.
- „Unknown Device“ und „Invalid Method“ kommen jeweils 1.530-mal vor.
- Mit der IQR-Methode wurden 508 Ausreißer bei Transaction_Amount identifiziert.
- Ein extremer Betrag liegt bei rund 50.000 USD.
- Die Datentypen entsprechen den erwarteten Typen.
- Der ursprüngliche Fraud-Anteil beträgt 4,9 %.

4.3 Quality-Checks

Auf Basis des Profilings wurden fünf Quality-Checks definiert.

Tabelle 1: Ergebnisse der fünf Quality-Checks

Check	Regel	Verstöße
QC1	Transaction_Amount muss > 0 sein	0
QC2	Transaction_ID muss eindeutig sein	1.000
QC3	Time_of_Transaction muss zwischen 0 und 23 liegen	0
QC4	Fraudulent muss 0 oder 1 sein	0
QC5	Device_Used / Payment_Method ohne Platzhalterwerte	3.060

Die fünf Checks folgen der Idee einer task-dependent Metrik. Der Qualitätswert ergibt sich als Anteil der Regelverstöße an allen Datensätzen, abgezogen von 1. Ein Wert von 1,000 bedeutet, dass kein Datensatz gegen die Regel verstößt.

4.3.1 Interpretation der Checks

QC1 prüft, ob jeder Transaktionsbetrag größer als null ist. Negative oder null Beträge wären bei einer Zahlung nicht plausibel.

QC2 verlangt, dass jede Transaction_ID nur einmal vorkommt. Doppelte Schlüssel können bei Verknüpfungen oder Aggregationen dazu führen, dass Beträge mehrfach berücksichtigt werden.

QC3 begrenzt die Stunde der Transaktion auf den Bereich von 0 bis 23.

QC4 lässt für Fraudulent nur die Werte 0 und 1 zu. Abweichende Werte würden die spätere Evaluation verfälschen.

QC5 prüft Platzhalter wie „Unknown Device“ und „Invalid Method“. Diese Werte sind technisch nicht leer, stellen fachlich aber fehlende Information dar und betreffen damit insbesondere die Dimension Completeness.

4.4 Isolation Forest

Für die Anomalieerkennung wurden fünf numerische Spalten verwendet:

- Transaction_Amount
- Time_of_Transaction
- Previous_Fraudulent_Transactions
- Account_Age
- Number_of_Transactions_Last_24H

Zeilen mit fehlenden Werten in diesen Spalten wurden entfernt. Dadurch reduzierte sich der Datensatz von 51.000 auf 46.065 Zeilen.

Isolation Forest wurde mit einem contamination-Parameter von 0,05 trainiert. Damit wird angenommen, dass ungefähr 5 % der Daten als Anomalien gelten. Für die Reproduzierbarkeit wurde der Zufallsstartwert auf `random_state = 42` gesetzt. Das Modell stammt aus der scikit-learn-Bibliothek und basiert auf dem Verfahren von Liu et al. (2008).

5 Ergebnisse

5.1 Datenqualität

Abbildung 1 zeigt drei zentrale Befunde: fehlende Werte pro Spalte, doppelte Transaction_IDs und verdächtige Platzhalterwerte. Besonders auffällig sind die nahezu identischen Anteile fehlender Werte in den fünf betroffenen Spalten. Die Werte liegen zwischen 4,84 % und 5,00 %. Dies spricht eher für einen systematischen Fehler bei der Datenerfassung als für zufällig fehlende Einzelwerte.




Abbildung 1: Fehlende Werte, Duplikate und verdächtige Werte im Datensatz

5.2 Ausreißer

Die Boxplots in Abbildung 2 zeigen die Verteilung ausgewählter numerischer Variablen. Während Account_Age und Number_of_Transactions_Last_24H keine auffälligen Ausreißer zeigen, weist Transaction_Amount einen deutlichen Ausreißer bei etwa 50.000 USD auf.




Abbildung 2: Boxplots der numerischen Spalten zur Identifikation von Ausreißern

5.3 Isolation-Forest-Ergebnisse

Von 46.065 Transaktionen wurden 2.304 (5,0 %) als Anomalien eingestuft. Der Vergleich mit den tatsächlichen Fraud-Labels zeigt jedoch nur 120 Übereinstimmungen von 2.259 echten Fraud-Fällen. Das entspricht einer Erkennungsrate von 5,3 %.

Tabelle 2: Confusion Matrix – Isolation Forest vs. tatsächliche Fraud-Labels

	Vorhergesagt: Normal	Vorhergesagt: Anomalie
Tatsächlich Normal	41.622	2.184
Tatsächlich Fraud	2.139	120




Abbildung 3: Isolation Forest Anomalien und Confusion Matrix

6 Bewertung der Isolation-Forest-Ergebnisse

Die Gesamtgenauigkeit (Accuracy) liegt bei 91 %. Angesichts der Klassenverteilung ist diese Kennzahl wenig aussagekräftig: Ein Modell, das jede Transaktion als „Normal“ einstuft, würde bereits 95,1 % erreichen.

Aussagekräftiger sind Precision und Recall für die Klasse Fraud. Von den 2.304 als Anomalie markierten Transaktionen waren 120 tatsächlich betrügerisch. Daraus ergibt sich eine Precision von 5,21 %. Von den 2.259 echten Betrugsfällen wurden 120 gefunden, also ein Recall von 5,31 %.

Beide Werte liegen praktisch auf dem Niveau der Basisrate von 4,90 %. Würde man aus 46.065 Transaktionen zufällig 2.304 auswählen, wären rechnerisch etwa 113 Betrugsfälle zu erwarten. Isolation Forest findet 120 und liegt damit nur rund 6 % über dem Zufallsniveau.

Bei statistischen Ausreißern zeigt sich dagegen ein anderes Bild: Sämtliche 484 Transaktionen mit einem Betrag über 20.000 USD wurden als Anomalie eingestuft, darunter der Maximalwert von 49.997,80 USD.

Der Grund für den Unterschied liegt darin, was Isolation Forest misst. Das Verfahren isoliert Datenpunkte, die sich in den verwendeten Merkmalen deutlich von der übrigen Datenmenge entfernen. Betrug äußert sich in diesem Datensatz jedoch überwiegend nicht durch außergewöhnliche Beträge oder Uhrzeiten, sondern durch Muster innerhalb normaler Wertebereiche.

Statistische Auffälligkeit und Betrug sind daher zwei verschiedene Eigenschaften.

Ein unüberwachtes Verfahren kann statistische Ausreißer erkennen, ist aber in dieser Konfiguration nicht ausreichend, um Fraud zuverlässig zu erkennen.

7 Fazit und Ausblick

Der untersuchte Datensatz weist mehrere Qualitätsprobleme auf. In fünf Spalten fehlen jeweils rund 5 % der Werte. Hinzu kommen 1.000 doppelte Transaction_IDs und 3.060 Einträge mit Platzhalterwerten. Betroffen sind insbesondere die Dimensionen Completeness und Free-of-Error.

Isolation Forest findet statistische Ausreißer zuverlässig, vor allem den Betrag von rund 50.000 USD. Bei den echten Betrugsfällen ist die Leistung dagegen sehr schwach: Von 2.259 Fällen werden nur 120 erkannt, also 5,3 %.

Für eine produktive Datenpipeline ergeben sich vier zentrale Empfehlungen:

1. Die Ursache der fehlenden Werte sollte im Erfassungsprozess geklärt werden. Der gleichmäßige Anteil von rund 5 % spricht für einen systematischen Fehler.

2. Doppelte Transaction_IDs sollten vor der weiteren Verarbeitung entfernt oder korrigiert werden.
3. Platzhalter wie „Invalid Method“ sollten als fehlende Werte behandelt werden und nicht als gültige Kategorien.
4. Für die Betrugserkennung reicht Isolation Forest allein nicht aus. Ein überwachtes Verfahren mit den vorhandenen Fraud-Labels wäre sinnvoll.

Das aktuelle Modell nutzt nur fünf numerische Spalten. Payment_Method und Location wurden nicht berücksichtigt, obwohl dort möglicherweise zusätzliche Muster liegen. Eine sinnvolle Erweiterung wäre daher, diese Variablen zu kodieren und in ein weiterführendes Modell einzubeziehen.

8 Literaturverzeichnis

- Abedjan, Z., Golab, L., & Naumann, F. (2015). Profiling Relational Data: A Survey. *The VLDB Journal*, 24(4), S. 557–581. <https://doi.org/10.1007/s00778-015-0389-y>
- Fraud Detection Dataset. Kaggle. <https://www.kaggle.com> (Datensatz, abgerufen im Sommersemester 2026).
- Liu, F. T., Ting, K. M., & Zhou, Z.-H. (2008). Isolation Forest. *Proceedings of the 2008 Eighth IEEE International Conference on Data Mining (ICDM)*, S. 413–422. <https://doi.org/10.1109/ICDM.2008.17>
- Pedregosa, F., Varoquaux, G., Gramfort, A., et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, S. 2825–2830. <https://www.jmlr.org/papers/volume12/pedregosa11a/pedregosa11a.pdf>
- Pipino, L. L., Lee, Y. W., & Wang, R. Y. (2002). Data Quality Assessment. *Communications of the ACM*, 45(4), S. 211–218. <https://doi.org/10.1145/505248.506010>

9 Transparenzangabe zur Nutzung von KI-Tools

Im Rahmen dieses Projekts wurde ChatGPT als Hilfsmittel eingesetzt.

Was: ChatGPT wurde verwendet, um mehrere Datensätze auf Kaggle hinsichtlich ihrer Eignung für die Projektziele zu vergleichen und zu bewerten. Außerdem unterstützte ChatGPT bei der Recherche wissenschaftlicher Literatur, beim Auffinden relevanter Fachartikel, DOI-Links und weiterer Quellen. Darüber hinaus half ChatGPT dabei, geeignete Lernmaterialien, insbesondere französischsprachige YouTube-Videos und Online-Tutorials, zu finden, theoretische Konzepte zu erläutern, Fragen zur Python-Programmierung zu beantworten und Textpassagen des Berichts sprachlich zu überarbeiten.

Wie: Die endgültige Auswahl des Datensatzes erfolgte durch den Autor. Vorgeschlagene Quellen und Lernmaterialien wurden anschließend selbst geprüft und ausgewählt. Während der Umsetzung im Jupyter Notebook wurde ChatGPT genutzt, um einzelne Fragen zur Python-Programmierung zu klären und Fehlermeldungen zu verstehen. Für den Projektbericht wurden einzelne Abschnitte mit Unterstützung von ChatGPT sprachlich überarbeitet; alle Inhalte, Zahlen und Schlussfolgerungen stammen vom Autor und wurden von ihm geprüft.

Wo: ChatGPT wurde bei der Auswahl des Datensatzes, der Literaturrecherche, der Suche nach ergänzenden Lernmaterialien, bei einzelnen Programmierfragen im Jupyter Notebook sowie bei der sprachlichen Überarbeitung einzelner Abschnitte des Berichts eingesetzt.

Alle Analysen, Visualisierungen, Ergebnisse, Interpretationen und Schlussfolgerungen wurden vom Autor selbst durchgeführt, überprüft und verantwortet.