

Data Quality & Anomaly Detection auf Finanztransaktionsdaten

*Profiling, Quality-Checks und Isolation Forest am Beispiel des Fraud Detection
Dataset*

Projektbericht — Big Data Management, Sommersemester 2026

Alain Zidane Momo Fofou
Matrikelnummer: 602032
Wirtschaftsinformatik B.Sc.
TU Clausthal

Betreuer: M.Sc. Denis Kruschinski
Abgabedatum: 14.08.2026

Datenqualität ist in Data-Management-Projekten oft der größte Aufwand, bevor sinnvolle Analysen möglich sind. Gerade bei Finanzdaten ist das kritisch, da fehlerhafte Daten zu falschen Entscheidungen und unzuverlässigen Betrugsmodellen führen können. Diese Arbeit untersucht einen Datensatz mit 51.000 Finanztransaktionen (Fraud Detection Dataset, Kaggle) anhand eines dreistufigen Quality-Konzepts: systematisches Profiling, fünf automatisierte Quality-Checks und Anomalieerkennung mit Isolation Forest. Das Profiling zeigt fünf Spalten mit jeweils etwa 5 % fehlenden Werten, 1.000 doppelte Transaction_IDs und 3.060 Einträge mit Platzhalterwerten wie „Invalid Method“. Drei von fünf Quality-Checks bestehen ohne Verstöße, zwei zeigen die genannten Probleme. Isolation Forest identifiziert zuverlässig statistische Ausreißer, insbesondere bei Transaction_Amount, erkennt jedoch nur 5,3 % der tatsächlichen Fraud-Fälle. Daraus folgt, dass statistische Anomalieerkennung Datenqualitätsprobleme gut aufdecken kann, für die Betrugserkennung allein jedoch nicht ausreicht. Die Arbeit liefert konkrete Handlungsempfehlungen für eine produktive Datenpipeline.

Contents

1	Einleitung	3
2	Verwandte Arbeiten	3
3	Konzept	4
4	Umsetzung	4
4.1	Datensatz	4
4.2	Profiling	5
4.3	Quality-Checks	5
4.4	Isolation Forest	5
5	Ergebnisse	6
5.1	Datenqualität	6
5.2	Ausreißer	6
5.3	Isolation-Forest-Ergebnisse	7
6	Fazit und Ausblick	8
	Transparenzangabe zur Nutzung von KI-Tools	9

1 Einleitung

In Data-Management-Projekten ist Datenqualität oft der größte Aufwand. Bevor man mit irgendeiner Analyse oder einem Machine-Learning-Modell anfängt, muss man wissen, ob die Daten überhaupt vertrauenswürdig sind. Fehlende Werte, doppelte Einträge oder ungültige Kategorien können dazu führen, dass spätere Analysen falsche Ergebnisse liefern, ohne dass man es merkt.

In diesem Projekt wird ein Datensatz mit 51.000 Finanztransaktionen (Fraud Detection Dataset, Kaggle) [2] systematisch untersucht. Ziel ist es, ein Quality-Konzept zu bauen, das aus drei Teilen besteht: einem Profiling, das die wichtigsten Eigenschaften des Datensatzes beschreibt, fünf automatisierten Quality-Checks, die typische Probleme aufdecken, und einer Anomalieerkennung mit Isolation Forest, die ungewöhnliche Transaktionen identifiziert.

Die Fragestellung lautet: Welche Datenqualitätsprobleme stecken in einem Datensatz mit Finanztransaktionen — gemessen an den Dimensionen von Pipino et al. [5] — und wie gut erkennt Isolation Forest nach Liu et al. [3] verdächtige Transaktionen, wenn man die Fraud-Labels nicht zum Trainieren benutzt?

Der Bericht ist wie folgt aufgebaut: Kapitel 2 stellt verwandte Arbeiten vor, Kapitel 3 beschreibt das Konzept, Kapitel 4 die Umsetzung im Notebook, Kapitel 5 die Ergebnisse und Kapitel 6 fasst die wichtigsten Erkenntnisse zusammen.

2 Verwandte Arbeiten

Für dieses Projekt sind drei Arbeiten besonders relevant.

Pipino, Lee und Wang [5] beschreiben in ihrem Artikel „Data Quality Assessment“, dass Datenqualität ein mehrdimensionales Konzept ist. Sie unterscheiden zwischen subjektiven Einschätzungen (wie Nutzer die Daten wahrnehmen) und objektiven Metriken, die direkt aus den Daten berechnet werden können. Für dieses Projekt sind vor allem die Dimensionen Completeness (Vollständigkeit), Free-of-Error (Fehlerfreiheit) und Consistent Representation (einheitliche Darstellung) relevant, da sie sich direkt auf den untersuchten Datensatz anwenden lassen.

Liu, Ting und Zhou [3] stellen mit Isolation Forest ein Verfahren vor, das Anomalien nicht über ein Profil normaler Daten erkennt, sondern Anomalien aktiv isoliert. Die Grundidee ist, dass Anomalien „wenige und unterschiedliche“ Datenpunkte sind, die sich dadurch leichter von der restlichen Datenmenge trennen lassen. Der Algorithmus baut viele zufällige Entscheidungsbäume und berechnet für jeden Datenpunkt einen Anomalie-Score zwischen 0 und 1. Ein Vorteil von Isolation Forest ist, dass keine gelabelten Trainingsdaten benötigt werden, was es für die vorliegende Aufgabe besonders geeignet macht.

Abedjan, Golab und Naumann [1] geben in ihrem Übersichtsartikel eine Klassifikation von Data-Profiling-Aufgaben. Für diese Arbeit ist vor allem die Kategorie der Einzelspalten-Analyse relevant, zu der die Autoren Kennzahlen wie die Anzahl fehlender Werte, die Anzahl eindeutiger Werte, den Datentyp einer Spalte und häufige Werte-

muster zählen. Darüber hinaus beschreiben sie, dass die Ergebnisse eines Profilings anschließend in Regeln überführt werden können, die in einer nachgelagerten Bereinigungsphase geprüft werden. Genau dieses Vorgehen wird im vorliegenden Projekt umgesetzt, indem aus den Profiling-Befunden die fünf Quality-Checks abgeleitet werden.

Alle drei Arbeiten bilden die theoretische Grundlage für das in diesem Projekt entwickelte Quality-Konzept: Pipino et al. liefern die Dimensionen für die Bewertung der Datenqualität, Abedjan et al. das methodische Vorgehen vom Profiling zu den abgeleiteten Regeln und Liu et al. die Methode für die Anomalieerkennung.

3 Konzept

Das entwickelte Quality-Konzept besteht aus drei aufeinander aufbauenden Schritten.

Schritt 1 — Profiling: Zunächst wird der Datensatz systematisch beschrieben. Dazu gehören die Größe des Datensatzes, die Datentypen jeder Spalte, der Anteil fehlender Werte, die Anzahl von Duplikaten sowie Ausreißer in den numerischen Spalten.

Schritt 2 — Quality-Checks: Auf Basis des Profilings werden fünf konkrete Regeln definiert, die automatisiert im Notebook geprüft werden. Jede Regel prüft eine bestimmte Eigenschaft, die laut Pipino et al. [5] für Datenqualität relevant ist, zum Beispiel ob Beträge plausibel sind oder ob IDs eindeutig sind.

Schritt 3 — Anomalieerkennung: Mit Isolation Forest werden Transaktionen identifiziert, die sich stark von der Mehrheit der Daten unterscheiden. Da der Datensatz eine Spalte mit echten Fraud-Labels enthält, können die gefundenen Anomalien anschließend mit den tatsächlichen Betrugsfällen verglichen werden. Dieser Vergleich zeigt, ob statistische Anomalieerkennung und Betrugserkennung dasselbe Ziel verfolgen oder ob es sich um unterschiedliche Probleme handelt.

Alle drei Schritte wurden in einem einzigen Jupyter Notebook mit Pandas, NumPy, scikit-learn, Matplotlib und Seaborn umgesetzt.

4 Umsetzung

4.1 Datensatz

Der verwendete Datensatz (Fraud Detection Dataset, Kaggle) [2] enthält 51.000 Finanztransaktionen mit 12 Spalten. Neben einer eindeutigen Transaction_ID enthält der Datensatz Informationen zu Transaktionsbetrag, -art, -zeitpunkt, genutztem Gerät, Standort, Zahlungsmethode sowie eine Spalte Fraudulent, die angibt, ob die Transaktion betrügerisch war.

4.2 Profiling

Beim Profiling wurden folgende Befunde festgestellt:

- Fünf Spalten (Transaction_Amount, Time_of_Transaction, Device_Used, Location, Payment_Method) weisen jeweils etwa 5 % fehlende Werte auf (zwischen 2.469 und 2.552 von 51.000 Zeilen).
- 1.000 Transaction_IDs kommen doppelt vor, 881 Zeilen sind komplette Duplikate.
- Die Werte „Unknown Device“ (Device_Used) und „Invalid Method“ (Payment_Method) kommen jeweils 1.530-mal vor – exakt gleich oft, was auf eine gemeinsame Ursache hindeutet.
- Bei Transaction_Amount wurden mit der IQR-Methode 508 Ausreißer identifiziert, darunter ein extremer Wert von rund 50.000 USD.
- Die Datentypen aller Spalten entsprechen den erwarteten Typen (z. B. float64 für Transaction_Amount, int64 für Fraudulent).
- Im ursprünglichen Datensatz beträgt der Fraud-Anteil 4,9 %. Nach dem Entfernen der Zeilen mit fehlenden Werten verbleiben 2.259 Fraud-Fälle im bereinigten Datensatz.

4.3 Quality-Checks

Auf Basis des Profilings wurden fünf Quality-Checks definiert (Tabelle 1).

Tabelle 1: Ergebnisse der fünf Quality-Checks

Check	Regel	Ergebnis
QC1	Transaction_Amount muss > 0 sein	0 Verstöße
QC2	Transaction_ID muss eindeutig sein	1.000 Verstöße
QC3	Time_of_Transaction muss zwischen 0 und 23 liegen	0 Verstöße
QC4	Fraudulent muss 0 oder 1 sein	0 Verstöße
QC5	Keine Platzhalterwerte in Device_Used / Payment_Method	3.060 Verstöße

Drei der fünf Checks zeigen keine Verstöße, was darauf hindeutet, dass die grundlegende Struktur der Daten korrekt ist. Die beiden fehlgeschlagenen Checks (QC2 und QC5) zeigen jedoch systematische Probleme, die insgesamt 4.060 Datensätze betreffen.

4.4 Isolation Forest

Für die Anomalieerkennung wurden fünf numerische Spalten verwendet: Transaction_Amount, Time_of_Transaction, Previous_Fraudulent_Transactions, Account_Age und Number_of_Transactions_Last_24H. Zeilen mit fehlenden Werten

in diesen Spalten wurden entfernt, wodurch sich der Datensatz von 51.000 auf 46.065 Zeilen reduzierte. Isolation Forest wurde mit einem contamination-Parameter von 0,05 trainiert, was bedeutet, dass etwa 5 % der Daten als Anomalien erwartet werden. Für die Reproduzierbarkeit der Ergebnisse wurde der Zufallsstartwert auf `random_state = 42` gesetzt. Das Modell stammt aus der scikit-learn-Bibliothek [4] und basiert auf dem Verfahren von Liu et al. [3].

5 Ergebnisse

5.1 Datenqualität

Abbildung 1 zeigt drei Diagramme: die fehlenden Werte pro Spalte, die Anzahl doppelter Transaction_IDs sowie die Häufigkeit der Platzhalterwerte „Unknown Device“ und „Invalid Method“. Auffällig ist, dass alle fünf betroffenen Spalten nahezu identische Anteile fehlender Werte aufweisen (zwischen 4,84 % und 5,00 %), was auf einen systematischen Fehler bei der Datenerfassung hindeutet, statt auf zufällig fehlende Einzelwerte.




Abbildung 1: Fehlende Werte, Duplikate und verdächtige Werte im Datensatz

5.2 Ausreißer

Abbildung 2 zeigt Boxplots für Transaction_Amount, Account_Age und Number_of_Transactions_Last_24H. Während Account_Age und Number_of_Transactions_Last_24H keine Ausreißer aufweisen, zeigt Transaction_Amount einen deutlichen Ausreißer bei etwa 50.000 USD, während der Großteil der Transaktionen zwischen 0 und 5.000 USD liegt.




Abbildung 2: Boxplots der numerischen Spalten zur Identifikation von Ausreißern

5.3 Isolation-Forest-Ergebnisse

Von den 46.065 Transaktionen wurden 2.304 (5,0 %) als Anomalien eingestuft, was dem eingestellten contamination-Wert entspricht. Der Vergleich mit den tatsächlichen Fraud-Labels (Tabelle 2) zeigt jedoch nur eine Übereinstimmung von 120 der 2.259 echten Fraud-Fälle, was einer Erkennungsrate von 5,3 % entspricht.

Tabelle 2: Confusion Matrix — Isolation Forest vs. tatsächliche Fraud-Labels

	Vorhergesagt: Normal	Vorhergesagt: Anomalie
Tatsächlich Normal	41.622	2.184
Tatsächlich Fraud	2.139	120




Abbildung 3: Isolation Forest Anomalien (links) und Confusion Matrix (rechts)

Die Gesamtgenauigkeit (Accuracy) liegt bei 91 %, was angesichts der Klassenverteilung (95,1 % Normal, 4,9 % Fraud) wenig aussagekräftig ist: Ein Modell, das jede Transaktion als „Normal“ einstuft, würde bereits eine Accuracy von 95,1 % erreichen.

6 Fazit und Ausblick

Der untersuchte Datensatz weist mehrere Qualitätsprobleme auf. In fünf Spalten fehlen jeweils rund 5 % der Werte. Hinzu kommen 1.000 doppelte Transaction_IDs und 3.060 Einträge mit Platzhalterwerten. Nach Pipino et al. [5] sind damit die Dimensionen Completeness, Uniqueness und Free-of-Error betroffen.

Isolation Forest identifizierte statistisch auffällige Transaktionen zuverlässig, insbesondere den extremen Betrag von rund 50.000 USD. Bei den echten Betrugsfällen versagte das Verfahren dagegen: Von 2.259 Fällen erkannte es nur 120, also 5,3 %. Der Grund liegt in den Daten selbst. Betrügerische Transaktionen bewegen sich der Höhe nach meist im normalen Bereich. Ein Verfahren, das allein nach statistisch auffälligen Werten sucht, kann sie deshalb kaum finden.

Für eine produktive Pipeline ergeben sich daraus vier Empfehlungen:

- Woher die fehlenden Werte stammen, muss im Erfassungsprozess geklärt werden. Der gleichmäßige Anteil von rund 5 % pro betroffener Spalte spricht für einen systematischen Fehler.
- Doppelte Transaction_IDs gehören vor jeder weiteren Verarbeitung entfernt oder korrigiert.
- Platzhalter wie „Invalid Method“ sind keine gültige Kategorie, sondern fehlende Werte, und sollten auch so behandelt werden.
- Für die Betrugserkennung reicht Isolation Forest allein nicht aus. Sinnvoll wäre ein überwachtes Verfahren, das mit den vorhandenen Fraud-Labels trainiert wird.

Das Modell nutzt nur die fünf numerischen Spalten. Payment_Method und Location blieben unberücksichtigt, obwohl dort möglicherweise Muster stecken. Diese Variablen zu kodieren und einzubeziehen, wäre der nächste sinnvolle Schritt.

Literaturverzeichnis

- [1] Ziawasch Abedjan, Lukasz Golab, and Felix Naumann. Profiling relational data: A survey. *The VLDB Journal*, 24(4):557–581, 2015. <https://doi.org/10.1007/s00778-015-0389-y>.
- [2] Kaggle. Fraud detection dataset. <https://www.kaggle.com>. Datensatz, abgerufen im Sommersemester 2026.
- [3] Fei Tony Liu, Kai Ming Ting, and Zhi-Hua Zhou. Isolation forest. In *Proceedings of the 2008 Eighth IEEE International Conference on Data Mining (ICDM)*, pages 413–422, 2008. <https://doi.org/10.1109/ICDM.2008.17>.
- [4] Fabian Pedregosa, Gaël Varoquaux, Alexandre Gramfort, Vincent Michel, Bertrand Thirion, Olivier Grisel, Mathieu Blondel, Peter Prettenhofer, Ron Weiss, Vincent Dubourg, Jake Vanderplas, Alexandre Passos, David Cournapeau, Matthieu Brucher, Matthieu Perrot, and Édouard Duchesnay. Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12:2825–2830, 2011. <https://www.jmlr.org/papers/volume12/pedregosa11a/pedregosa11a.pdf>.
- [5] Leo L. Pipino, Yang W. Lee, and Richard Y. Wang. Data quality assessment. *Communications of the ACM*, 45(4):211–218, 2002. <https://doi.org/10.1145/505248.506010>.

Transparenzangabe zur Nutzung von KI-Tools

Im Rahmen dieses Projekts wurde ChatGPT als Hilfsmittel eingesetzt.

Was: ChatGPT wurde verwendet, um mehrere Datensätze auf Kaggle hinsichtlich ihrer Eignung für die Projektziele zu vergleichen und zu bewerten. Außerdem unterstützte ChatGPT bei der Recherche wissenschaftlicher Literatur, beim Auffinden relevanter Fachartikel, DOI-Links und weiterer Quellen. Darüber hinaus half ChatGPT dabei, geeignete Lernmaterialien, insbesondere französischsprachige YouTube-Videos und Online-Tutorials, zu finden, um die verwendeten Methoden besser zu verstehen. Zusätzlich wurde ChatGPT genutzt, um einzelne theoretische Konzepte zu erläutern, Fragen zur Python-Programmierung zu beantworten und einzelne Textpassagen des Berichts sprachlich zu überarbeiten.

Wie: Zu Beginn des Projekts wurden mehrere Datensätze aus Kaggle recherchiert. ChatGPT unterstützte dabei, die Datensätze hinsichtlich ihres Inhalts, ihrer Datenqualität und ihrer Eignung für die Projektziele zu vergleichen. Die endgültige Auswahl des verwendeten Datensatzes erfolgte anschließend durch den Autor.

Bei der Literaturrecherche half ChatGPT, geeignete wissenschaftliche Veröffentlichungen, DOI-Links und weitere relevante Quellen zu identifizieren. Zusätzlich wurden passende Lernmaterialien, insbesondere französischsprachige YouTube-Videos

und Online-Tutorials, vorgeschlagen, um die theoretischen Grundlagen sowie den Isolation-Forest-Algorithmus besser zu verstehen. Die vorgeschlagenen Quellen und Lernmaterialien wurden anschließend vom Autor selbst geprüft und für das Projekt ausgewählt.

Während der Umsetzung im Jupyter Notebook wurde ChatGPT genutzt, um einzelne Fragen zur Python-Programmierung zu klären, Fehlermeldungen zu verstehen und mögliche Lösungsansätze zu diskutieren. Der Python-Code wurde anschließend vom Autor selbst erstellt, angepasst, ausgeführt und getestet.

Für den Projektbericht diente ChatGPT außerdem zur sprachlichen Überarbeitung einzelner Formulierungen. Alle Inhalte wurden vom Autor überprüft und bei Bedarf angepasst.

Wo: ChatGPT wurde bei der Auswahl des Datensatzes, der Literaturrecherche, der Suche nach ergänzenden Lernmaterialien, bei einzelnen Programmierfragen im Jupyter Notebook sowie bei der sprachlichen Überarbeitung einzelner Abschnitte des Berichts eingesetzt.

Alle Analysen, Visualisierungen, Ergebnisse, Interpretationen und Schlussfolgerungen wurden vom Autor selbst durchgeführt, überprüft und verantwortet.